

**TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI
PHÂN HIỆU TẠI TP. HỒ CHÍ MINH
BỘ MÔN CÔNG NGHỆ THÔNG TIN**



BÁO CÁO BÀI TẬP LỚN

KHAI PHÁ DỮ LIỆU

ĐỀ TÀI: Power Generation Forecasting

Giảng viên hướng dẫn: ThS. Nguyễn Thiện Dương

Sinh viên thực hiện: Nguyễn Đức Khoa - 6351071034

Lê Minh Hoàng - 6351071025

Lớp : CQ.CNTT.K63

Khoá : 63

Tp. Hồ Chí Minh, năm 2025

**TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI
PHÂN HIỆU TẠI TP. HỒ CHÍ MINH
BỘ MÔN CÔNG NGHỆ THÔNG TIN**



BÁO CÁO BÀI TẬP LỚN

KHAI PHÁ DỮ LIỆU

ĐỀ TÀI: Power Generation Forecasting

Giảng viên hướng dẫn: ThS. Nguyễn Thiện Dương

Sinh viên thực hiện: Nguyễn Đức Khoa - 6351071034

Lê Minh Hoàng - 6351071025

Lớp : CQ.CNTT.K63

Khoá : 63

Tp. Hồ Chí Minh, năm 2025

LỜI CẢM ƠN

Trong quá trình theo học môn Data Mining (Khai phá dữ liệu) cùng thầy Dương, tui em đã được thầy dạy và truyền đạt rất nhiều kiến thức bổ ích có thể hỗ trợ con đường sự nghiệp của chúng em sau này.

Chúng em xin bày tỏ lòng biết ơn sâu sắc đến thầy Dương, người đã tận tình hướng dẫn, chỉ bảo và hỗ trợ em trong suốt quá trình học tập.

Chúng em chúc thầy có thật nhiều sức khỏe để có thể đi đầu tiếp những “chuyến đò” tiếp theo.

Mặc dù đã cố gắng hết sức, song đồ án khó tránh khỏi những thiếu sót. Em rất mong nhận được sự góp ý của quý thầy cô để có thể hoàn thiện hơn trong tương lai.

Em xin chân thành cảm ơn!

Nguyễn Đức Khoa

Lê Minh Hoàng

NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Tp. Hồ Chí Minh, ngày tháng năm
Giáo viên hướng dẫn

ThS. Nguyễn Thiện Dương

MỤC LỤC

CHƯƠNG 1: LÝ DO CHỌN DATASET VÀ GIỚI THIỆU TỔNG QUAN DATASET.....	1
1.1 Giới thiệu tổng quan Dataset.....	1
1.1.1 Nguồn dữ liệu sử dụng.....	3
1.1.1.1 Bối cảnh thu thập dữ liệu SCADA.....	3
1.1.2 Mô tả chi tiết dữ liệu.....	3
1.1.3 Mô tả mục đích bài toán.....	4
1.1.4 Tiền xử lý dữ liệu.....	5
1.1.4.1 Làm sạch dữ liệu (Xử lý thiếu và Ngoại lệ).....	5
1.1.4.2. Chuyển đổi kiểu dữ liệu.....	6
1.1.4.3. Lọc dữ liệu không hợp lệ.....	6
1.1.4.4. Chọn lọc và định hình lại dữ liệu.....	6
1.1.4.5. Chuẩn hóa dữ liệu.....	7
1.1.4.6. Chia dữ liệu thành tập huấn luyện và kiểm tra.....	7
1.1.4.7. Tạo tập dữ liệu chuỗi thời gian cho mô hình LSTM.....	7
1.1.4.8 Tích hợp dữ liệu.....	8
1.1.4.9 Thu giảm, rút gọn dữ liệu (Kỹ thuật Đặc trưng).....	8
1.1.5 Dữ liệu sau tiền xử lý.....	9
1.1.6 Chuẩn bị dữ liệu để huấn luyện và kiểm thử.....	9
1.1.7 Train set (và phương pháp Validation).....	10
1.1.8 Test set (và phương pháp Backtesting).....	10
1.1.9 Mô tả chi tiết các thuộc tính trong dataset.....	10
1.2. Giới thiệu các công cụ sử dụng trong đồ án.....	12
1.2.1 Tổng quan về Công nghệ (Tech Stack).....	12
1.2.2 Giới thiệu Python3 và Thư viện Học máy.....	12
1.2.3 Giới thiệu Công cụ Triển khai (FastAPI & TimescaleDB).....	12
CHƯƠNG 2: THUẬT TOÁN KHAI THÁC DỮ LIỆU SỬ DỤNG.....	14
2.1 Sử dụng thuật toán LIGHTGBM cho dự báo đa bước.....	14
2.1.1. Tổng quan về các thuật toán dựa trên cây quyết định.....	14
2.1.2. Lý do lựa chọn LightGBM.....	15
2.1.3. Quy trình thực hiện (Multi-step Forecasting Strategy).....	16
2.1.3.1. So sánh Chiến lược Dự quy và Trực tiếp.....	16

2.1.3.1.1. Kết quả đạt được (Các chỉ số đánh giá).....	17
2.1.4. So sánh đánh giá bằng Skill Score.....	18
2.2 Sử dụng mô hình LSTM cho dự báo chuỗi thời gian.....	18
2.2.1. Lý do lựa chọn LSTM.....	18
2.2.2. Quy trình huấn luyện LSTM.....	19
2.2.3. Kết quả đánh giá.....	20
2.3 MLOps – giám sát và phát hiện trôi.....	20
2.3.1. Lý do cần giám sát mô hình.....	20
2.3.2. Phát hiện Data Drift.....	21
2.3.3. Kết quả.....	22
CHƯƠNG 3: KẾT LUẬN.....	23
3.1. Kết quả thực nghiệm.....	23
3.1.1. Phân tích và so sánh kết quả.....	23
3.1.2. Ưu điểm và hạn chế của từng mô hình.....	25
3.1.3. Kết luận.....	26
3.2. Hướng phát triển.....	26
3.3. Chương trình ứng dụng demo.....	27
3.3.1. Mục tiêu của ứng dụng demo.....	27
3.3.2. Kiến trúc tổng quan.....	28
3.3.3. Luồng dữ liệu và quy trình xử lý.....	30
3.3.4. Giao diện và API ứng dụng.....	32
3.3.4.1. Frontend – Vue 3 SPA.....	32
3.3.4.2. API – FastAPI.....	32
3.3.5. Cách chạy demo (tóm tắt).....	33
3.3.5.1. Backend.....	33
3.3.5.2. Frontend.....	33
3.3.6. Giới hạn và ghi chú triển khai.....	33
3.3.7. Kết luận.....	34
3.3.8. Giao diện chương trình.....	34
BẢNG PHÂN CÔNG NHIỆM VỤ TRONG NHÓM.....	40
TÀI LIỆU THAM KHẢO.....	41

DANH MỤC CÁC BẢNG, SƠ ĐỒ, HÌNH

Danh sách bảng

<i>Bảng 1. Mô tả chi tiết các thuộc tính trong dataset.....</i>	<i>15</i>
<i>Bảng 2. Kết quả mô hình LightGBM.....</i>	<i>27</i>
<i>Bảng 3. Kết quả mô hình LSTM.....</i>	<i>27</i>

Danh sách sơ đồ

<i>Sơ đồ 1. Sơ đồ tổng quan LSTM.....</i>	<i>23</i>
---	-----------

Danh sách hình

<i>Hình 3.1. Giao diện chính của chương trình.....</i>	<i>38</i>
<i>Hình 3.2. Giao diện hiển thị các độ đo (metrics).....</i>	<i>39</i>
<i>Hình 3.3. Giao diện tạo 1 Forecast.....</i>	<i>40</i>
<i>Hình 3.4. Giao diện nạp thêm dữ liệu để có thể dự đoán.....</i>	<i>40</i>
<i>Hình 3.5. Giao diện config chi tiết các cho forecast.....</i>	<i>40</i>
<i>Hình 3.6. Giao diện xem chi tiết các biểu đồ.....</i>	<i>40</i>
<i>Hình 3.7. Giao diện quản lý dữ liệu.....</i>	<i>41</i>
<i>Hình 3.8. Giao diện phân tích các giá trị thiếu.....</i>	<i>41</i>
<i>Hình 3.9. Giao diện lịch sử các phân tích.....</i>	<i>41</i>
<i>Hình 3.10. Giao diện quản lý các model (ví dụ ở đây là lightgbm).....</i>	<i>41</i>
<i>Hình 3.11. Giao diện chi tiết số đo của model (metrics).....</i>	<i>43</i>

CHƯƠNG 1: LÝ DO CHỌN DATASET VÀ GIỚI THIỆU TỔNG QUAN DATASET

1.1 Giới thiệu tổng quan Dataset

Trong bối cảnh chuyển dịch sang năng lượng sạch, nguồn năng lượng tái tạo như điện mặt trời và điện gió đóng vai trò ngày càng quan trọng trong chiến lược phát triển năng lượng bền vững toàn cầu. Việc dự báo chính xác sản lượng hoặc nhu cầu năng lượng từ các nguồn này giúp:

- Điều tiết lưới điện ổn định hơn, giảm rủi ro quá tải
- Lập kế hoạch cung – cầu phù hợp.
- Tối ưu chi phí vận hành và đầu tư.
- Tích hợp năng lượng tái tạo vào hệ thống điện một cách hiệu quả hơn.

Trong học máy và khai thác dữ liệu, *Power Forecasting* là một bài toán dự báo giá trị tương lai (sản lượng hoặc mức năng lượng tiêu thụ) dựa trên các thông tin lịch sử và các biến liên quan, đặc biệt là **thời tiết**. Các nghiên cứu về việc dự báo năng lượng tái tạo cho thấy mối liên hệ quan trọng giữa điều kiện khí tượng và lượng điện tạo ra hoặc tiêu thụ trong từng khoảng thời gian cụ thể.

Xây dựng mô hình dự báo "Energy delta [Wh]" theo từng giờ trong tương lai, dựa trên dữ liệu lịch sử và các biến khí tượng, nhằm phục vụ:

- Dự báo biến động năng lượng trong ngắn hạn/h dài hạn.
- Giúp nhà điều hành hệ thống điện lập kế hoạch hoạt động phù hợp (ví dụ: dự báo sau 1 giờ, 6 giờ hay 24 giờ).
- So sánh hiệu quả của các mô hình khai thác dữ liệu khác nhau.

Phát biểu bài toán

Cho dữ liệu thời gian gồm:

- Tập lịch sử với các đặc trưng:
X: tập các biến độc lập gồm khí tượng (bức xạ mặt trời, nhiệt độ, độ ẩm,...) và các biến hỗ trợ khác theo thời gian.
- Biến mục tiêu:
y: Energy delta [Wh] tại thời điểm t.

Yêu cầu: Xây dựng mô hình dự báo (dự báo trong tương lai), sao cho sai số dự báo được **tối thiểu hóa**.

Bài toán có thể định nghĩa như một bài toán hồi quy (regression) hoặc dự báo chuỗi thời gian (time-series forecasting):

Dự báo “Energy delta [Wh]” trong T tương lai (ví dụ next hour, next 24h) dựa trên dữ liệu lịch sử và các biến khí tượng tại thời điểm hiện tại và quá khứ.

Ứng dụng trong hệ thống điện

Việc dự báo chính xác mức năng lượng (product/delta) giúp:

- Điều tiết lưới điện: Ngăn chặn quá tải, thiếu điện khi giá trị biến động lớn.
- Lập kế hoạch cung cấp năng lượng & tối ưu chi phí mua thêm hoặc bán bớt năng lượng dự trữ.
- Hỗ trợ kinh tế – kỹ thuật: quyết định đầu tư, vận hành dựa trên dự báo

Lợi ích trong nghiên cứu

- Phát hiện mối quan hệ giữa thời tiết và năng lượng.
- So sánh năng lực dự báo của các thuật toán học máy truyền thống (ví dụ LightGBM, XGBoost) và mạng nơ-ron/deep learning (như LSTM).
- Nâng cao khả năng ứng dụng mô hình dự báo vào Smart Grid, IoT, điều khiển năng lượng tự động.

1.1.1 Nguồn dữ liệu sử dụng

Dữ liệu được cung cấp dưới dạng tệp **Renewable.csv**, mô phỏng đầu ra từ hệ thống SCADA (Supervisory Control and Data Acquisition) – hệ thống được sử dụng phổ biến trong các nhà máy điện mặt trời thực tế để thu thập, giám sát và điều khiển dữ liệu từ hàng trăm thiết bị hiện trường như cảm biến, biến tần (inverter), và bộ điều khiển.



1.1.1.1 Bối cảnh thu thập dữ liệu SCADA

Trong các nhà máy điện mặt trời (PV Plant) thực tế, dữ liệu không tồn tại ở dạng tĩnh (CSV) mà được thu thập liên tục theo thời gian thực. Hệ thống SCADA đóng vai trò trung tâm, truyền nhận dữ liệu giữa máy chủ và các thiết bị ngoại vi thông qua các giao thức truyền thông công nghiệp như:



- **Modbus:**

Là giao thức phổ biến, hoạt động theo mô hình **master-slave**, trong đó SCADA sẽ đọc dữ liệu từ các “thanh ghi” (registers) của thiết bị. Ví dụ, thư viện pymodbus trong Python có thể được dùng để truy vấn giá trị công suất hiện tại của từng biến tần theo chu kỳ nhất định.

- **IEC 61850:**

Là một tiêu chuẩn hiện đại hơn, được thiết kế riêng cho hệ thống điện. Thay vì các thanh ghi đơn giản, dữ liệu được lưu trữ theo cấu trúc hướng đối tượng, giúp truy xuất nhanh và bao gồm cả thông tin siêu dữ liệu (metadata) như cờ chất lượng (.q), trạng thái thiết bị, hoặc tín hiệu lỗi.

Dữ liệu trong tệp **Renewable.csv** là **phiên bản tổng hợp cuối cùng** từ các nguồn dữ liệu thô này, được xử lý và kết hợp lại để phục vụ cho mục đích nghiên cứu và mô phỏng dự báo.

1.1.2 Mô tả chi tiết dữ liệu

Dữ liệu SCADA của nhà máy PV là dạng chuỗi thời gian có mật độ cao, được ghi lại theo chu kỳ rất ngắn (vài giây hoặc vài phút).

Với một nhà máy điện mặt trời quy mô trung bình, hệ thống có thể tạo ra hàng nghìn điểm dữ liệu mỗi phút, bao gồm các chỉ số như công suất tức thời, nhiệt độ môi trường, bức xạ mặt trời (GHI), hướng gió, tốc độ gió, và nhiều thông số kỹ thuật khác.

Do khối lượng và tốc độ ghi dữ liệu rất lớn, việc lưu trữ và truy vấn loại dữ liệu này đòi hỏi cơ sở dữ liệu chuỗi thời gian chuyên dụng (Time-Series Database – TSDB) thay vì các hệ quản trị cơ sở dữ liệu thông thường.

Một số hệ thống TSDB phổ biến gồm:

- **InfluxDB:**

Là cơ sở dữ liệu NoSQL được thiết kế chuyên biệt cho chuỗi thời gian, phù hợp với các bài toán có độ đặc (cardinality) thấp. Tuy nhiên, hiệu suất ghi giảm khi số lượng cảm biến và chỉ số tăng cao.

- **TimescaleDB:**


Là phần mở rộng (extension) của PostgreSQL, cho phép lưu trữ và truy vấn dữ liệu chuỗi thời gian bằng cú pháp SQL quen thuộc. TimescaleDB có hiệu năng tốt hơn với dữ liệu có độ đặc cao và hỗ trợ phân tích phức tạp, rất hữu ích cho các bài toán kỹ thuật đặc trưng (feature engineering).

EDA


Dữ liệu thu thập từ:

From Time : 2017-01-01 00:00:00

To Time : 2022-10-02 17:45:00




Hình 1.1. Dữ liệu tiêu thụ năm 2018




Hình 1.2. Dữ liệu tiêu thụ năng lượng qua các năm


Energy Consumption by Month



Hình 1.3. Dữ liệu tiêu thụ theo tháng



Hình 1.4. Dữ liệu tiêu thụ theo mỗi 15 phút



Hình 1.4. Dữ liệu theo từng giờ

1.1.3 Mô tả mục đích bài toán

Mục tiêu chính là dự báo công suất phát điện mặt trời (PV power) trong khoảng ngắn hạn (ví dụ 15 phút – vài giờ tới).

Dự báo chính xác là yếu tố then chốt trong việc điều độ hệ thống điện, bởi sản lượng từ nguồn năng lượng mặt trời có độ biến động cao, phụ thuộc nhiều vào điều kiện thời tiết.

Tầm quan trọng của dự báo công suất PV:

- **Ổn định lưới điện:**

Khi mây che hoặc thời tiết thay đổi đột ngột, công suất PV có thể giảm mạnh trong vài phút. Nếu có dự báo chính xác, các nhà vận hành có thể chủ động cân bằng giữa cung và cầu năng lượng.

- **Quản lý dự phòng:**

Trong trường hợp dự báo không chắc chắn (ví dụ: $100 \text{ MW} \pm 50 \text{ MW}$), hệ thống cần duy trì các nguồn điện dự phòng quay (spinning reserve) để bù đắp sai lệch – điều này gây tốn kém.

Dự báo xác suất giúp định lượng rủi ro và tối ưu hóa mức dự phòng.

- **Giảm chi phí vận hành:**

Khi có mô hình dự báo chính xác, hệ thống có thể điều phối năng lượng hiệu quả hơn, giảm chi phí lưu trữ, vận hành và hao tổn.

1.1.4 Tiền xử lý dữ liệu

Trong thực tế, dữ liệu SCADA **hiếm khi hoàn hảo**. Có thể xuất hiện lỗi do mất kết nối mạng, hư cảm biến, hoặc sự cố thiết bị, dẫn đến dữ liệu bị thiếu, sai lệch, hoặc không hợp lý. Vì vậy, giai đoạn tiền xử lý dữ liệu (data preprocessing) là **cực kỳ quan trọng** để đảm bảo đầu vào cho mô hình là sạch và ổn định.

1.1.4.1 Làm sạch dữ liệu (Xử lý thiếu và Ngoại lệ)

Xử lý dữ liệu thiếu (Missing Data):

- *Khoảng trống ngắn (< 1 giờ):*
Có thể xử lý bằng nội suy tuyến tính (Linear Interpolation) hoặc PCHIP (Piecewise Cubic Hermite Interpolation), giúp duy trì độ trơn mượt của chuỗi thời gian.
- *Khoảng trống dài (> 1 giờ):*
Các phương pháp nội suy không còn hiệu quả. Lúc này cần áp dụng kỹ thuật **học máy để điền dữ liệu** như:
 - **KNN Imputer** (dựa trên lân cận gần nhất)
 - **MICE (Multiple Imputation by Chained Equations)**, tận dụng mối tương quan giữa các đặc trưng (ví dụ: giữa GHI và thời gian trong ngày).

Xử lý ngoại lệ (Outlier Detection):

- *Loại bỏ giá trị phi vật lý:* Ví dụ như công suất âm, hoặc giá trị vượt quá định mức inverter.
- *Giữ lại sự kiện vật lý thực:* Ví dụ, khi công suất giảm đột ngột do mây hoặc bóng cây che, đó là tín hiệu thật cần giữ lại để mô hình học được đặc tính biến thiên tự nhiên.

1.1.4.2. Chuyển đổi kiểu dữ liệu

Cột Time được chuyển về định dạng datetime. Việc chuẩn hóa định dạng thời gian giúp:

- Dễ dàng sắp xếp và xử lý chuỗi thời gian.

- Trích xuất được các đặc trưng liên quan đến thời gian (giờ, ngày, tháng...).
- Sử dụng trực tiếp cho các mô hình yêu cầu timestamp như Prophet.

1.1.4.3. Lọc dữ liệu không hợp lệ

Các hàng trong đó Energy delta[Wh] = 0 được loại bỏ. Những giá trị bằng 0 có thể đại diện cho:

- Khoảng thời gian không có sản xuất/tiêu thụ năng lượng.
- Dữ liệu bị thiếu hoặc lỗi thiết bị đo.
- Nhiễu làm giảm khả năng học của mô hình.

Loại bỏ các hàng này giúp tập dữ liệu tập trung vào các biến động năng lượng thực sự.

1.1.4.4. Chọn lọc và định hình lại dữ liệu

Một DataFrame mới (df1) được tạo chỉ gồm:

- Time
- Energy delta[Wh]

Sau đó, cột Time được đặt làm chỉ mục (index).

Điều này chuyển dữ liệu thành dạng Time Series, phù hợp với các mô hình dự báo.

Đối với mô hình Prophet, dữ liệu tiếp tục được định hình lại bằng cách:

- Đổi tên Time → **ds**
- Đổi tên Energy delta[Wh] → **y**

1.1.4.5. Chuẩn hóa dữ liệu

Cột **Energy delta[Wh]** được chuẩn hóa bằng **MinMaxScaler** đưa toàn bộ dữ liệu vào khoảng **[0, 1]**.

Việc chuẩn hóa đặc biệt quan trọng cho các mô hình:

- **LSTM**, vốn nhạy cảm với sự khác biệt lớn về giá trị.
- Các mô hình Gradient Boosting khi dữ liệu phân tán rộng.

Chuẩn hóa giúp mô hình hội tụ nhanh và ổn định hơn.

1.1.4.6. Chia dữ liệu thành tập huấn luyện và kiểm tra

Dữ liệu được chia theo tỉ lệ:

- **80%** cho tập huấn luyện
- **20%** cho tập kiểm tra

Điều này đảm bảo việc đánh giá mô hình được khách quan, tránh overfitting khi mô hình được kiểm tra trên dữ liệu chưa từng thấy trước đó.

1.1.4.7. Tạo tập dữ liệu chuỗi thời gian cho mô hình LSTM

Một hàm tùy chỉnh **create_dataset** được sử dụng để biến đổi chuỗi năng lượng thành dạng phù hợp với LSTM.

Hàm này tạo ra:

- **Xs** → chuỗi đầu vào với độ dài n_steps
- **ys** → giá trị cần dự báo tại bước kế tiếp

Cách dựng dữ liệu dạng sliding window này giúp LSTM học được:

- Xu hướng theo thời gian
- Quan hệ phụ thuộc ngắn hạn và dài hạn
- Chu kỳ lặp lại (daily/seasonal pattern)

1.1.4.8 Tích hợp dữ liệu

Bước này kết hợp **chuỗi thời gian năng lượng (energy_wh)** với các nguồn dữ liệu ngoại sinh (exogenous) như:

- Dữ liệu khí tượng (GHI, nhiệt độ, độ ẩm, tốc độ gió)
- Các đặc trưng thiên văn (vị trí mặt trời, góc chiếu sáng,...)

1.1.4.9 Thu giảm, rút gọn dữ liệu (Kỹ thuật Đặc trưng)

Đây là bước quan trọng nhất để cải thiện hiệu suất mô hình. Chúng ta chuyển đổi dữ liệu thô thành các đặc trưng có ý nghĩa hơn.

Đặc trưng Khí tượng & Thiên văn:

- Các đặc trưng cơ bản: GHI, Nhiệt độ Môi trường, Tốc độ Gió, Độ che phủ Mây.
- Các đặc trưng tính toán (Thiên văn): Vị trí của mặt trời, có thể dự đoán chính xác.
- Góc Thiên đỉnh (Zenith Angle, Θ_z): Góc giữa mặt trời và phương thẳng đứng. Đây là yếu tố dự báo quan trọng nhất về công suất tiềm năng.
- Khối lượng Không khí (Air Mass, AM): Độ dài quang học của khí quyển mà ánh sáng mặt trời phải đi qua, thường được tính xấp xỉ bằng AM

Đặc trưng Phái sinh (Loại bỏ Xu hướng):

- Chỉ số Bầu trời Quang đăng (Clear Sky Index - CSI): Thay vì dự đoán công suất thô (bị chi phối bởi chu kỳ ngày/đêm), chúng ta dự đoán một chỉ số đã được chuẩn hóa.
- $CSI = GHI_{\text{measured}} / GHI_{\text{clearsky}}$.
- Việc này loại bỏ xu hướng (de-trend) thành phần tất định (sự quay của Trái đất) và cho phép mô hình tập trung vào việc dự đoán thành phần ngẫu nhiên (ảnh hưởng của mây).

Đặc trưng Suy giảm Hiệu suất (Quan trọng):

- Bám bẩn (Soiling): Sự tích tụ bụi bẩn làm giảm hiệu suất theo thời gian. Chúng ta có thể định lượng điều này bằng cách sử dụng các thuật toán như SRR (Stochastic Rate and Recovery) để tạo ra một đặc trưng `soiling_loss_factor` hàng ngày.
- Che khuất (Shading): Các sự kiện sụt giảm công suất đột ngột do bóng che (từ cây cối, các dãy pin khác). Chúng ta định lượng điều này bằng cách so sánh công suất thực tế (P_{actual}) với công suất lý tưởng (P_{ideal}) được tính toán từ một mô hình vật lý. Đặc trưng $\text{shading_ratio} = P_{\text{actual}} / P_{\text{ideal}}$ giúp mô hình phân biệt giữa mất công suất do mây và mất công suất do che khuất vật lý.

1.1.5 Dữ liệu sau tiền xử lý

Tập dữ liệu cuối cùng để huấn luyện bao gồm một tập hợp phong phú các đặc trưng nội sinh (trở công suất) và ngoại sinh (thời tiết, thiên văn, suy giảm), cho phép mô hình hiểu được bối cảnh vật lý của việc tạo ra công suất.

1.1.6 Chuẩn bị dữ liệu để huấn luyện và kiểm thử

Việc chia dữ liệu huấn luyện và kiểm thử trong bài toán chuỗi thời gian **phải bảo toàn thứ tự thời gian** – không được trộn lẫn như K-Fold thông thường, để tránh rò rỉ dữ liệu (data leakage).

- **Phương pháp xác thực tiến về phía trước (Walk-Forward Validation):**

Dữ liệu được huấn luyện theo từng giai đoạn tăng dần:

- Fold 1: Huấn luyện từ tháng 1–3 → Dự báo tháng 4
- Fold 2: Huấn luyện từ tháng 1–4 → Dự báo tháng 5
- ...

Cách làm này phản ánh sát thực tế vận hành.

- **Tập kiểm thử (Backtesting):**

Là phần dữ liệu cuối (ví dụ 3 tháng cuối năm), hoàn toàn chưa được mô hình “nhìn thấy”, dùng để đánh giá khả năng tổng quát của mô hình.

1.1.7 Train set (và phương pháp Validation)

Chúng ta sử dụng Kiểm định chéo Chuỗi thời gian (Time-Series Cross-Validation), cụ thể là phương pháp Xác thực Tiến về phía trước (Walk-Forward Validation) hoặc "cửa sổ mở rộng" (expanding window).

Quy trình này mô phỏng thực tế sản xuất :

- Fold 1: Huấn luyện trên, Dự đoán
- Fold 2: Huấn luyện trên, Dự đoán
- Fold 3: Huấn luyện trên , Dự đoán ...

1.1.8 Test set (và phương pháp Backtesting)

Tập kiểm tra (test set) là một khối dữ liệu cuối cùng, hoàn toàn chưa được thấy (hold-out set) (ví dụ: 3 tháng cuối cùng của dữ liệu) mà mô hình chưa bao giờ được huấn luyện. Quá trình đánh giá cuối cùng trên tập này được gọi là backtesting.

1.1.9 Mô tả chi tiết các thuộc tính trong dataset

Sau bước kỹ thuật đặc trưng, các thuộc tính quan trọng nhất được sử dụng để huấn luyện bao gồm:

Bảng 1. Mô tả chi tiết các thuộc tính trong dataset

Tên cột (Feature)	Kiểu dữ liệu	Mô tả	Ghi chú
DateTime	datetime	Thời điểm ghi nhận dữ liệu	Dữ liệu dạng chuỗi thời gian theo giờ
Energy delta [Wh]	numeric	Sự thay đổi năng lượng tính theo Watt-giờ giữa hai timestamp liên tiếp	Là mục tiêu dự báo trong bài toán; phản ánh mức thay đổi tiêu thụ/sản xuất năng lượng
Temperatur e [°C]	float	Nhiệt độ môi trường tại thời điểm ghi nhận	Ảnh hưởng tới hiệu suất nguồn năng lượng tái tạo

Pressure [hPa]	float	Áp suất khí quyển	Biến điều kiện thời tiết
Humidity [%]	float	Độ ẩm tương đối của không khí	Có thể ảnh hưởng tới lượng bức xạ mặt trời hiệu quả
Wind Speed [m/s]	float	Tốc độ gió	Ảnh hưởng tới sản lượng điện gió
Wind Direction [deg]	float	Hướng gió	Giúp mô tả điều kiện gió chi tiết hơn
Solar Radiation [W/m²]	float	Lượng bức xạ mặt trời nhận được	Yếu tố chính ảnh hưởng tới điện mặt trời
Cloud Cover [%]	float	Độ che phủ mây	Tương quan với bức xạ mặt trời và sản lượng điện
Visibility [km]	float	Tầm nhìn	Tỷ lệ điều kiện khí tượng
Dew Point [°C]	float	Điểm sương	Thông tin bổ sung về độ ẩm
Precipitation [mm]	float	Lượng mưa	Ảnh hưởng tới điện mặt trời và điều kiện khí hậu

1.2. Giới thiệu các công cụ sử dụng trong đồ án

Đồ án sử dụng **công nghệ hiện đại**, tối ưu cho bài toán xử lý dữ liệu thời gian thực và triển khai mô hình học máy (MLOps). Toàn bộ pipeline bao gồm:

- Thu thập & xử lý dữ liệu (Python, Pandas)
- Huấn luyện mô hình (LightGBM, Scikit-learn)

- Triển khai mô hình dưới dạng API (FastAPI)

1.2.1 Tổng quan về Công nghệ (Tech Stack)

Ngăn xếp này được thiết kế để xử lý dữ liệu thời gian thực, huấn luyện các mô hình mạnh mẽ và phục vụ các dự báo thông qua một API, mô phỏng một hệ thống sản xuất thực tế.

1.2.2 Giới thiệu Python3 và Thư viện Học máy

- Python 3.10+: Ngôn ngữ lập trình cốt lõi.
- LightGBM: Khung Gradient Boosting hiệu suất cao, là mô hình dự báo chính của chúng ta.
- Scikit-learn: Được sử dụng cho các mô hình RandomForest (để so sánh), các đường ống tiền xử lý (pipelines) và các chỉ số đánh giá.
- Pymodbus: Thư viện Python để giao tiếp với các thiết bị Modbus (mô phỏng việc thu thập dữ liệu).

1.2.3 Giới thiệu Công cụ Triển khai (FastAPI & TimescaleDB)

- TimescaleDB (PostgreSQL): Cơ sở dữ liệu chuỗi thời gian được lựa chọn (như đã thảo luận trong 1.1.2) để lưu trữ hiệu quả hàng tỷ điểm dữ liệu SCADA.
- FastAPI: Một khung web Python hiện đại, không đồng bộ, hiệu suất cao để xây dựng các API. Nó được sử dụng để "phục vụ" (serve) các mô hình đã huấn luyện, cho phép các ứng dụng khác (như bảng điều khiển dashboard) gọi và nhận dự báo theo thời gian thực.
- asyncpg: Trình điều khiển (driver) PostgreSQL không đồng bộ, cho phép FastAPI truy vấn TimescaleDB mà không chặn vòng lặp sự kiện (event loop), tối đa hóa thông lượng.

CHƯƠNG 2: THUẬT TOÁN KHAI THÁC DỮ LIỆU SỬ DỤNG

2.1 Sử dụng thuật toán LIGHTGBM cho dự báo đa bước

2.1.1. Tổng quan về các thuật toán dựa trên cây quyết định

Các mô hình dựa trên cây quyết định (decision-tree-based models) luôn là lựa chọn mạnh mẽ cho các bài toán dự báo trên dữ liệu dạng bảng (tabular data), đặc biệt khi dữ liệu có tính phi tuyến, biến động mạnh hoặc có nhiều đặc trưng tương tác lẫn nhau. Một cây quyết định đơn lẻ (single decision tree) thường dễ giải thích, nhưng dễ mắc hai hạn chế:

- **Quá khớp (overfitting)** do mô hình ghi nhớ quá mức các mẫu huấn luyện.
- **Độ ổn định thấp**, thay đổi nhỏ ở dữ liệu có thể làm thay đổi cấu trúc cây rất nhiều.

Để khắc phục, các phương pháp **ensemble learning** được sử dụng để kết hợp nhiều cây “yếu” thành một mô hình mạnh hơn:

- **Bagging (Bootstrap Aggregating)** – ví dụ Random Forest.
Các cây được huấn luyện độc lập trên các tập dữ liệu bootstrap khác nhau, giúp giảm phương sai và tăng sự ổn định.
- **Boosting** – ví dụ Gradient Boosting, XGBoost, LightGBM.
Các cây được huấn luyện tuần tự để sửa phần lỗi (residuals) của tổ hợp cây trước đó, dẫn tới mô hình mạnh và thể hiện hiệu năng cao trên nhiều bài toán.

Ưu điểm chung của nhóm mô hình tree-based:

- Không yêu cầu chuẩn hóa thang đo.
- Tự động học tương tác giữa các đặc trưng.

- Khả năng mô hình hóa quan hệ phi tuyến.
- Hoạt động tốt trên dữ liệu có nhiễu vừa phải.

2.1.2. Lý do lựa chọn LightGBM



Trong đề án này, LightGBM được lựa chọn làm mô hình chính cho nhiệm vụ dự báo PV (photovoltaic power forecasting) vì các ưu điểm sau:

(1) Tốc độ huấn luyện vượt trội

LightGBM sử dụng chiến lược tăng trưởng **leaf-wise** thay vì **level-wise**. Điều này giúp cây tập trung mở rộng các nhánh có mức giảm lỗi lớn nhất, từ đó cải thiện chất lượng mô hình với số lượng mức phân chia ít hơn.

Kết hợp với kỹ thuật:

- Histogram-based splitting
- Gradient-based One-Side Sampling (GOSS)
- Exclusive Feature Bundling (EFB)

LightGBM đạt tốc độ nhanh hơn đáng kể so với các thuật toán boosting truyền thống.

(2) Hỗ trợ dự báo định lượng (quantile regression)

Đây là điểm rất quan trọng vì dự báo năng lượng thường đi kèm bất định. LightGBM hỗ trợ mô hình hóa phân vị (quantile) chỉ bằng cách thay đổi hàm mất mát, rất phù hợp cho các ứng dụng vận hành năng lượng.

(3) Dễ tích hợp với Scikit-learn

Do LightGBM có API tương thích sklearn, nó dễ dàng tích hợp với pipeline tiền xử lý, quy trình cross-validation, và hyperparameter tuning như Optuna hoặc Bayesian Optimization.

(4) Khả năng mở rộng

LightGBM hoạt động tốt với dữ liệu rất lớn và có thể huấn luyện phân tán (distributed training). Dù dữ liệu trong nghiên cứu không quá lớn, khả năng mở rộng giúp hệ thống có tiềm năng mở rộng trong tương lai.

Vì các lý do trên, LightGBM được xem là một lựa chọn phù hợp và hiệu quả cho mô hình dự báo PV đa bước.

2.1.3. Quy trình thực hiện (Multi-step Forecasting Strategy)

Bài toán dự báo PV thường yêu cầu dự đoán giá trị trong tương lai theo nhiều bước (multi-step), chẳng hạn dự báo công suất 24 giờ tiếp theo theo từng giờ. Điều này tạo ra thách thức vì mô hình phải học được quan hệ thời gian lẫn phụ thuộc ngoại sinh (như GHI – Global Horizontal Irradiance).

Có hai chiến lược chính:

2.1.3.1. So sánh Chiến lược Đệ quy và Trực tiếp

(A) Chiến lược Đệ quy (Recursive Strategy)

- Huấn luyện một mô hình duy nhất để dự đoán bước $t+1$.
- Sau đó dùng chính dự đoán của mô hình để dự báo $t+2$, $t+3$, ...

Nhược điểm:

- Tích lũy lỗi mạnh: sai số bước đầu lan truyền sang các bước sau.
- Phải dự báo cả các biến ngoại sinh (GHI, CSI, nhiệt độ...) cho tương lai xa
→ làm tăng thêm một bài toán dự báo chồng lên nhau.

(B) Chiến lược Trực tiếp (Direct Strategy)

Huấn luyện N mô hình riêng biệt, với N là số bước dự báo.

Ví dụ dự báo 24 bước:

- Mô hình 1 → dự báo $t+1$
- Mô hình 2 → dự báo $t+2$
- ...
- Mô hình 24 → dự báo $t+24$

Ưu điểm:

- Không tích lũy lỗi.
- Không cần dự báo biến ngoại sinh tại $t+k$.
- Mỗi mô hình tập trung vào một chân trời dự báo cụ thể → thường chính xác hơn.

Nhược:

- Phải huấn luyện nhiều mô hình hơn.

Trong nghiên cứu này, chiến lược Trực tiếp được sử dụng vì tính ổn định và hiệu suất vượt trội.

2.1.3.1.1. Kết quả đạt được (Các chỉ số đánh giá)

Các chỉ số đánh giá chính:

- **RMSE / MAE**
- **MAPE** (không phù hợp với PV do ban đêm có giá trị bằng 0)

- **sMAPE** (ổn định hơn MAPE)

$$WMAPE = \frac{\sum |F - O|}{\sum |O|}$$

Kết quả backtesting cho thấy LightGBM-Direct đạt hiệu năng cao nhất trong các mô hình tree-based được thử nghiệm.

2.1.4. So sánh đánh giá bằng Skill Score


Skill Score (SS) được dùng để đo mức cải thiện so với mô hình baseline “Persistence” ($t+1 = t$).

Phương pháp	WMAPE (%)	Skill Score
Persistence (baseline)	28.2	0.00
LightGBM (Recursive)	19.8	0.30
LightGBM (Direct)	12.9	0.54

Kết luận: LightGBM (Direct) là mô hình tree-based tốt nhất trong nghiên cứu.

2.2 Sử dụng mô hình LSTM cho dự báo chuỗi thời gian

2.2.1. Lý do lựa chọn LSTM



Sơ đồ 1. Sơ đồ tổng quan LSTM

Trong khi LightGBM xử lý dữ liệu dạng bảng rất tốt, nó không học sâu quan hệ thời gian dài (long-term temporal dependencies). Do đó, một mô hình học sâu dành riêng cho chuỗi thời gian được đưa vào so sánh: **Long Short-Term Memory (LSTM)**.

LSTM phù hợp vì:

- Có khả năng ghi nhớ phụ thuộc xa trong chuỗi.
- Mô hình hóa các dạng biến động phức tạp của dữ liệu PV (mây, bão, thay đổi thời tiết).
- Tận dụng tốt dữ liệu liên tục theo thời gian, điều mà mô hình tree-based không tối ưu.

Trong thực nghiệm, LSTM được sử dụng để:

- Dự báo điểm (point forecast)
- So sánh hiệu năng trực tiếp với LightGBM

Tuy không cung cấp phân vị dự báo như LightGBM quantile, LSTM vẫn là baseline mạnh trong các nghiên cứu liên quan đến chuỗi thời gian năng lượng.

2.2.2. Quy trình huấn luyện LSTM

Dữ liệu chuỗi được chuyển thành tập các chuỗi đầu vào (windows) với chiều dài lookback L.

Ví dụ:

- Input: công suất trong 24 giờ trước
- Output: dự báo $t+1$ hoặc multi-step dựa trên direct training

Kiến trúc LSTM được tối ưu bằng:

- Số lớp LSTM
- Số đơn vị ẩn
- Dropout
- Learning rate (Adam optimizer)

Mỗi chân trời dự báo ($t+1 \rightarrow t+24$) có một mô hình riêng, tương tự chiến lược Direct của LightGBM.

2.2.3. Kết quả đánh giá

So sánh LSTM với LightGBM cho thấy:

- LSTM hoạt động tốt trong các khoảng thời gian có tính tuần hoàn mạnh (buổi trưa).
- LSTM kém hơn LightGBM trong điều kiện biến động mạnh (nhiều mây), do khó học các quan hệ phi tuyến từ dữ liệu ngoại sinh như GHI.

Tổng quan, LSTM là baseline sâu hữu ích nhưng LightGBM vẫn vượt trội trên dữ liệu bằng kết hợp ngoại sinh.

2.3 MLOps – giám sát và phát hiện trôi

2.3.1. Lý do cần giám sát mô hình

Mô hình dự báo năng lượng sau khi triển khai có thể bị suy giảm hiệu suất theo thời gian do:

- **Data Drift** (thay đổi phân phối dữ liệu đầu vào)
Ví dụ: cảm biến GHI bị lệch, nhiễu hoặc thay thế.
- **Concept Drift** (thay đổi quan hệ đầu vào → đầu ra)
Ví dụ: tấm pin bị suy giảm công suất theo năm.

Do đó, cần có cơ chế giám sát liên tục để quyết định khi nào nên:

- Cảnh báo hệ thống
- Thu thập dữ liệu mới
- Kích hoạt huấn luyện lại (retraining trigger)

2.3.2. Phát hiện Data Drift

Các phương pháp áp dụng:

(1) So sánh thống kê

- Mean, variance
- Wasserstein distance
- KL divergence

(2) Kiểm định thống kê hai mẫu

- KS-test cho biến liên tục
- Chi-square cho biến rời rạc

(3) Change Point Detection

- PELT
- Bayesian Online Change Point Detection

(4) Classifier-based Drift Detection

Huấn luyện một mô hình phân biệt dữ liệu "cũ" và "mới".
Nếu accuracy cao → drift.

Các đặc trưng giám sát:

- GHI, CSI
- Công suất đo được
- Tỷ lệ missing values
- Tương quan giữa GHI và công suất

2.3.3. Kết quả

Hệ thống giám sát giúp:

- Phát hiện sớm cảm biến hoạt động bất thường.
- Nhận diện sự thay đổi điều kiện môi trường theo mùa.
- Cung cấp tín hiệu đáng tin cậy cho pipeline huấn luyện lại mô hình.

Kết hợp với LightGBM và LSTM, hệ thống dự báo PV trở nên thích ứng và ổn định hơn trong thời gian dài.

CHƯƠNG 3: KẾT LUẬN

3.1. Kết quả thực nghiệm

Sau khi huấn luyện hai mô hình LightGBM và LSTM trên cùng tập dữ liệu và điều kiện đánh giá, thu được kết quả sau:

Bảng 2. Kết quả mô hình LightGBM

Metric	Giá trị
MAE	216.7774
RMSE	410.9909
MAPE	39.61%
R^2	0.8860

Bảng 3. Kết quả mô hình LSTM

Metric	Giá trị
MAE	243.0091
RMSE	421.9718
MAPE	45.32%
R^2	0.8799

3.1.1. Phân tích và so sánh kết quả

(1) Phân tích theo MAE

LightGBM có MAE = 216.8, tốt hơn LSTM (243.0).

Điều này cho thấy trung bình mỗi lần dự báo, LightGBM sai ít hơn khoảng 26 kW.

Nguyên nhân:

- LightGBM xử lý tốt các quan hệ phi tuyến giữa các feature ngoại sinh như GHI, CSI, nhiệt độ.
- LSTM phụ thuộc vào cấu trúc chuỗi và khó học các feature mạnh dạng tabular.

(2) Phân tích theo RMSE

RMSE của LightGBM thấp hơn ($410.9 < 421.9$).

Việc sai số bị bình phương khiến RMSE phản ứng mạnh với những điểm sai lệch lớn.

Điều này cho thấy:

- LightGBM ổn định hơn trong các thời điểm công suất cao (buổi trưa), nơi sai số lớn sẽ bị phạt nặng.
- LSTM gặp khó khi dữ liệu có biến động đột ngột (chuyển mây – nắng), vốn rất phổ biến trong dữ liệu PV.

(3) Phân tích MAPE

MAPE của LightGBM = $39.61\% < \text{LSTM} = 45.32\%$.

→ LightGBM sai thấp hơn theo phần trăm so với dữ liệu thực tế.

Nguyên nhân chính:

- LSTM khó dự báo chính xác khi công suất thấp hoặc gần bằng 0, làm MAPE tăng mạnh.
- LightGBM xử lý tốt các feature ngoại sinh giúp mô hình hóa giai đoạn sáng sớm / chiều tối chính xác hơn.

(4) Phân tích theo R^2

LightGBM đạt $R^2 = 0.886$, cao hơn LSTM 0.8799.

→ LightGBM giải thích tốt hơn sự biến thiên của dữ liệu công suất PV.

Điều này phù hợp với bản chất dữ liệu:

- Dữ liệu PV phụ thuộc mạnh vào GHI, góc mặt trời, điều kiện thời tiết.
- Các mối quan hệ này mang tính phi tuyến nhưng rất tabular, phù hợp với LightGBM.
- LSTM, dù mạnh với chuỗi thời gian, nhưng không khai thác tốt mối quan hệ này nếu không có feature engineering chuyên sâu.

3.1.2. Ưu điểm và hạn chế của từng mô hình

(A) LightGBM

Ưu điểm

- Huấn luyện nhanh, tiêu tốn ít tài nguyên.
- Khả năng xử lý dữ liệu bảng xuất sắc.
- Tận dụng tốt thông tin từ các biến ngoại sinh.
- Hiệu suất cao và ổn định trong điều kiện thời tiết biến động.
- Dễ triển khai, dễ tinh chỉnh, giải thích được (feature importance).

Hạn chế

- Không học được quan hệ chuỗi dài hạn (long-term dependency).
- Cần feature engineering cẩn thận để mô hình tốt nhất.
- Không mô phỏng được tự nhiên tính chu kỳ như LSTM.

(B) LSTM

Ưu điểm

- Mô hình tốt chuỗi thời gian phụ thuộc dài.
- Tự động trích xuất đặc trưng theo thời gian.
- Phù hợp trong các hệ thống có chu kỳ mạnh và ít biến ngoại sinh.

Hạn chế

- Huấn luyện lâu, dễ overfitting.
- Nhạy cảm với hyperparameter.
- Dự báo kém khi biến thiên đột ngột (cloud transients).
- Hiệu suất thấp hơn LightGBM trên dữ liệu PV dạng tabular.

3.1.3. Kết luận

Kết quả thực nghiệm cho thấy:

- LightGBM vượt trội hơn LSTM trên tất cả các độ đo.
- Sự chênh lệch không quá lớn nhưng ổn định, cho thấy LightGBM là lựa chọn phù hợp hơn cho dữ liệu PV có nhiều đặc trưng ngoại sinh.
- LSTM vẫn là baseline mạnh nhưng chưa đủ hiệu quả trong điều kiện thời tiết biến động nhanh hoặc dữ liệu phức tạp.

3.2. Hướng phát triển

Từ kết quả trên, một số hướng nghiên cứu tiếp theo được đề xuất:

(1) Tăng cường feature engineering

- Thêm các đặc trưng như độ mây, góc mặt trời, ngày trong năm, chỉ số thời tiết.
- Tạo các lag features và rolling windows cho LightGBM.

(2) Kết hợp mô hình (Hybrid Modeling)

- Sử dụng LightGBM để dự báo tầm xa, LSTM cho short-term forecasting.
- Hoặc ensemble hai mô hình để đạt hiệu suất tốt hơn.

(3) Sử dụng LSTM nâng cao

- BiLSTM, CNN-LSTM, Seq2Seq, Attention-based LSTM.
- Transformer Time Series (Temporal Fusion Transformer).

(4) Dự báo phân vị (Probabilistic Forecasting)

- Dùng LightGBM Quantile để ước lượng bất định (uncertainty).
- Cung cấp dải dự báo (prediction intervals)

(5) Ứng dụng MLOps

- Thiết lập pipeline giám sát drift và tự động huấn luyện lại.
- Theo dõi hiệu suất theo mùa (ánh sáng thay đổi theo tháng).

3.3. Chương trình ứng dụng demo

3.3.1. Mục tiêu của ứng dụng demo

Ứng dụng demo được xây dựng nhằm mô phỏng một hệ thống dự báo công suất điện mặt trời (PV forecasting) hoàn chỉnh từ dữ liệu đầu vào đến giao diện người dùng. Hệ thống đáp ứng các mục tiêu sau:

- Tự động hóa pipeline từ dữ liệu lịch sử (Renewable.csv) đến mô hình dự báo và API phục vụ dự báo theo thời gian thực.
- Huấn luyện mô hình dự báo cho nhiều horizon khác nhau (các bước 15 phút).
- Cung cấp khả năng dự báo tức thời (single-step) và dự báo theo lô (batch), đồng thời hỗ trợ sinh dải tin cậy (confidence interval) dựa trên ensemble.
- Giám sát chất lượng dữ liệu, phát hiện bất thường và so sánh mô hình với baseline truyền thống (persistence, MA-4).
- Cung cấp giao diện trực quan (UI) cho việc giám sát dữ liệu, thực hiện dự báo và quản lý mô hình.

Hệ thống này không chỉ minh họa pipeline dự báo PV mà còn phản ánh các yêu cầu của một ứng dụng sản xuất (production-level forecasting system).

3.3.2. Kiến trúc tổng quan

Ứng dụng demo tuân theo mô hình architecture-based-service kết hợp cùng dependency injection nhằm đảm bảo khả năng mở rộng và tái sử dụng. Thành phần khởi tạo và quản lý DI container được cấu hình trong container.Container (file container.py).

Các thành phần chính:

Mô hình dự báo chính – LightGBM

- Được huấn luyện cho từng horizon khác nhau.

- Tham số mô hình (ví dụ: `n_estimators=2000`, `learning_rate=0.05`, `num_leaves=64`) được ghi lại trong tài liệu kỹ thuật `TRAINING_GUIDE.md` và `REPORT.md`.
- Kết quả huấn luyện được quản lý dưới dạng artefact (model + metrics).

Các service chính

- **Forecasting Service:** xử lý logic dự báo, nạp mô hình tương ứng, sinh dự báo và xử lý dải tin cậy.
- **MetricsService:** tính toán chỉ số đánh giá và so sánh với baseline.

Kho lưu trữ artefact

- Sử dụng `ArtifactModelRepository`.
- Lưu trữ tại `backend/artifacts/` bao gồm:
 - Mô hình `LightGBM` theo từng horizon.
 - Tập JSON lưu trữ `MAE`, `RMSE`, `MAPE`, `R2`, `horizon`,...

Nguồn dữ liệu lịch sử

- Lấy từ `Renewable.csv` thông qua `CSS History Repository`.

Xử lý đặc trưng (Feature Engineering)

- Được triển khai trong `Feature Engineer` tại `feature engineering.py`.
- Toàn bộ logic tạo đặc trưng tham khảo trong `ENHANCED_FEATURES.md`.

3.3.3. Luồng dữ liệu và quy trình xử lý

Input dữ liệu

- Dữ liệu gốc: Renewable.csv.
- Quá trình profiling, baseline và kiểm tra chất lượng dữ liệu được thực hiện bằng data_profile.py.

Tạo đặc trưng

Feature Engineer sinh ra bộ đặc trưng mở rộng, bao gồm:

- Các độ trễ (lag): 1, 4, 8, 16, 24 bước.
- Thống kê trượt: 4, 8, 16, 32 bước.
- Lag cho biến thời tiết.
- Mã hóa chu kỳ:
 - Giờ trong ngày (sin/cos)
 - Ngày trong năm (sin/cos)
 - Tháng

Đây là bước quan trọng giúp LightGBM bắt được tính chu kỳ và tương quan thời gian của công suất PV.

Huấn luyện mô hình

- Mỗi horizon được huấn luyện riêng biệt ($h \in \{1, 4, 8, 24, 48\}$).

- Sử dụng LightGBM dựa trên tập đặc trưng đã sinh.
- Các artefact được lưu lại để phục vụ inference.

Inference và Confidence Interval

- API cung cấp các endpoint:
 - /forecast/next
 - /forecast/batch
- Khi bật chế độ ensemble:
 - Sử dụng Random Forest để sinh phân bố dự báo.
 - CI được suy ra từ phân bố hoặc từ hiệu chỉnh dựa trên MAE/RMSE.

Baseline để so sánh

- Persistence ($P(t+h) = P(t)$).
- Moving Average 4 bước (MA-4).

Được ghi lại trong REPORT.md và có thể tái tạo bằng lệnh:

```
python3 data_profile.py --csv Renewable.csv
```

Giám sát chất lượng dữ liệu

- Dùng IsolationForest (contamination = 0.1) để phát hiện:
 - Giá trị bất thường (outliers)

- Mẫu thiếu (missing)
- Độ lệch đột ngột trong phân bố
- UI hỗ trợ kiểm tra, upload và validate (hiện mô phỏng API).

3.3.4. Giao diện và API ứng dụng

3.3.4.1. Frontend – Vue 3 SPA

Gồm các tab chính:

- **Dashboard:** tổng quan mô hình.
- **Basic Forecast:** dự báo đơn bước.
- **Advanced Forecast:** dự báo đa bước, có dải tin cậy.
- **Data Quality:** giám sát lỗi và bất thường.
- **Historical Analysis:** phân tích chu kỳ, phân bố, mùa vụ.
- **Model Management:** xem metrics theo horizon, quản lý artefact.

Các component quan trọng:

- AdvancedForecast.vue
- ForecastChart.vue
- ModelManagement.vue

3.3.4.2. API – FastAPI

Cung cấp các nhóm endpoint:

- **Forecast API:**
/forecast/next, /forecast/batch
- **Historical Analysis:**
/analysis/historical
- **Model & Metrics:**
/model/list, /model/metrics

Toàn bộ mapping được ghi lại trong MODEL_OVERVIEW.md.

3.3.5. Cách chạy demo (tóm tắt)

3.3.5.1. Backend

```
pip install -r requirements.txt
python train_model.py
uvicorn main:app --reload
```

3.3.5.2. Frontend

```
npm install
npm run dev
```

3.3.6. Giới hạn và ghi chú triển khai


- Mô hình chính là LightGBM; ensemble chỉ sử dụng khi bật CI hoặc yêu cầu ổn định cao.
- Dữ liệu đang lưu trữ bằng CSV; để triển khai production có thể thay thế bởi PostgreSQL hoặc TimescaleDB.
- Horizon > 48 hiện vẫn đang ở trạng thái placeholder, nên chưa đủ thuật toán tối ưu và logging.

- Một số API quản lý dữ liệu trong UI là mock, nhưng đã có chuẩn hoá endpoint trong USAGE GUIDE.md.


3.3.7. Kết luận

Ứng dụng demo đã hoàn thiện một pipeline dự báo PV hiện đại, bao gồm đầy đủ các bước: xử lý dữ liệu – tạo đặc trưng – huấn luyện – đánh giá – triển khai API – giao diện trực quan. Mô hình LightGBM cho chất lượng tốt, có thể kết hợp ensemble để tăng độ tin cậy. Hệ thống đủ linh hoạt để phát triển lên mức độ sản xuất, hỗ trợ mở rộng sang dữ liệu thời tiết thực hoặc tích hợp vào IoT PV monitoring.

3.3.8. Giao diện chương trình




Hình 3.1. Giao diện chính của chương trình




Hình 3.2. Giao diện hiển thị các độ đo (metrics)

The interface is divided into several sections. On the left, the "INPUTS" section includes a "Generate Forecast" button, a "Forecast Horizon" dropdown set to "1 steps (15 min)", a checkbox for "Include tree leaf indices", and a "Use Live Weather" checkbox. A "Forecast" button is at the bottom of this section. The "MODEL OUTLOOK" section below it is titled "Forecast Insights" and contains a message: "Run a forecast to unlock contextual insights." On the right, the "Forecast Output" section displays "No data yet. Run a forecast to see results." Below this, the "STEP-BY-STEP" section titled "Forecast Timeline" shows "Timeline will populate after you run a forecast." The "REPLAY" section titled "Recent Runs" states: "Completed forecasts will show up here with quick stats you can revisit."


Hình 3.3. Giao diện tạo 1 Forecast




Hình 3.4. Giao diện nạp thêm dữ liệu để có thể dự đoán



Hình 3.5. Giao diện config chi tiết các cho forecast



Hình 3.6. Giao diện xem chi tiết các biểu đồ




Hình 3.7. Giao diện quản lý dữ liệu


Missing Values Analysis

Column	Missing Count	Missing %	Status
Time	0	0.00%	EXCELLENT
Energy delta[Wh]	0	0.00%	EXCELLENT
GHI	0	0.00%	EXCELLENT
temp	0	0.00%	EXCELLENT
pressure	0	0.00%	EXCELLENT
humidity	0	0.00%	EXCELLENT

Hình 3.8. Giao diện phân tích các giá trị thiếu



Hình 3.9. Giao diện lịch sử các phân tích



Hình 3.10. Giao diện quản lý các model (ví dụ ở đây là lightgbm)

Model metrics	
Key performance indicators reported by the backend	
METRIC	VALUE
MAE	45.200
RMSE	67.800
R2_SCORE	0.850

| **Retraining** | |
| Start a retraining job and monitor its progress | |

Hình 3.11. Giao diện chi tiết số đo của model (metrics)

BẢNG PHÂN CÔNG NHIỆM VỤ TRONG NHÓM

Thành viên	Nhiệm vụ chính
Nguyễn Đức Khoa	Phân tích và Tiền xử lý Dữ liệu (Chương 1.1.4), Kỹ thuật Đặc trưng (Chương 1.1.4.3), Nghiên cứu và Triển khai Dự báo Xác suất (Chương 2.2), (Chương 2.1.4), dựng giao diện và viết API (Chương 3)
Lê Minh Hoàng	Phân tích và Tiền xử lý Dữ liệu, Xây dựng và Huấn luyện Mô hình (LightGBM, LSTM), Đánh giá Chỉ số Nâng cao (WMAPE, Skill Score) (Chương 2.1), Tinh chỉnh tham số, Tổng hợp Báo cáo.

TÀI LIỆU THAM KHẢO

MLOps for Time Series Forecasting:

- <https://github.com/JohnPPinto/energy-consumption-forecasting>
- <https://aws.amazon.com/blogs/machine-learning/automate-model-retraining-with-amazon-sagemaker-pipelines-when-drift-is-detected>
- <https://arxiv.org/html/2503.21966v1>

Model Architecture & Validation:

- <https://medium.com/@farihatulma/ria/time-series-evaluation-metrics-mape-vs-wmape-vs-smape-which-one-to-use-why-and-when-part1-32d3852b4779>
- <https://medium.com/@pacosun/respect-the-order-cross-validation-in-time-series-7d12beab79a1>
- <https://openforecast.org/2024/05/25/recursive-vs-direct-forecasting-strategy>

Feature Engineering (Physics-Aware):

- <https://www.osti.gov/servlets/purl/1419409> (Soiling - SRR Method)
- [https://www.researchgate.net/publication/379044214_Detection_of_Shading_for_Solar_Power_Forecasting_Using_Machine_Learning_Techniques_\(Shading\)](https://www.researchgate.net/publication/379044214_Detection_of_Shading_for_Solar_Power_Forecasting_Using_Machine_Learning_Techniques_(Shading))
- [https://www.researchgate.net/publication/364435917_Solar_Forecasts_Based_on_the_Clear_Sky_Index_or_the_Clearness_Index_Which_Is_Better_\(CSI\)](https://www.researchgate.net/publication/364435917_Solar_Forecasts_Based_on_the_Clear_Sky_Index_or_the_Clearness_Index_Which_Is_Better_(CSI))

Uncertainty Quantification:

- https://medium.com/@suraj_bansal/quantile-regression-in-python-with-lightgbm-predicting-percentiles-part-1-460e6756a053
- <https://arxiv.org/pdf/2211.14545> (Quantile GBDT)

Infrastructure & Data Collection:

- <https://medium.com/timescale/timescaledb-vs-influxdb-for-time-series-data-timescale-influx-sql-nosql-36489299877> (TSDB)
- <https://neon.com/guides/timescale-fastapi> (FastAPI + Timescale)
- <https://github.com/pymodbus-dev/pymodbus> (Modbus).